

SVEUČILIŠTE U ZAGREBU

FAKULTET STROJARSTVA I BRODOGRADNJE

Fruit detection and pose estimation

**Instancna segmentacija 3D printanih modela voća primjenom
YOLOv8 nano arhitekture**

Student: Krešimir Hartl

Kolegij: Humanoidna robotika

Zagreb, travanj 2026.

1. UVOD

U okviru kolegija Humanoidna robotika, zadatak ovog rada bio je razviti sustav za detekciju i instancnu segmentaciju 3D printanih modela voća. U robotici se često susrećemo s potrebom za preciznim lociranjem objekata kako bi robotski manipulatori mogli sigurno interagirati s okolinom. Za ovaj zadatak odabrana je arhitektura YOLOv8 nano (n-seg) zbog svog izvrsnog omjera brzine obrade i preciznosti, što ju čini pogodnom za izvođenje u stvarnom vremenu na ugrađenim sustavima humanoidnih robota.


2. OPIS SKUPA PODATAKA

Proces prikupljanja podataka bio je kolaborativan. Autor je prikupio podatke za klasu crvena jabuka (desk i box slike). Standardizacija je uključivala re-mapiranje klasa u jedinstveni format. Skup je podijeljen na trening (70%), validaciju (20%) i testiranje (10%). Primijenjene su augmentacije poput mozaika i nasumične rotacije kako bi se spriječila prenaučenosť.

3. METODOLOGIJA I TRENIRANJE


Treniranje je provedeno pomoću PyTorch frameworka kroz 100 epoha. Korišten je početni learning rate od 0.01 uz SGD optimizator. Zadnjih 10 epoha provedeno je bez mozaik augmentacije radi finetuninga rubova maski. Hardverska podrška uključivala je NVIDIA RTX 4060 GPU.

4. REZULTATI I VIZUALIZACIJA



Slika 1. Konvergencija mAP50 metrike (Box i Mask).

Analiza konvergencije gubitaka



Slika 2. Analiza gubitaka (Loss functions) kroz epohe.

Tablica 1. Rezultati detekcije po klasama na testnom skupu.

Klasa	mAP50 (Box)	mAP50 (Mask)
Crvena jabuka	0.930	0.908
Zelena jabuka	0.912	0.893
Limun	0.915	0.887
Orah	0.957	0.952
Naranča	0.967	0.967

5. ZAKLJUČAK

Implementacija YOLOv8 nano modela za instancnu segmentaciju voća pokazala se uspješnom. Unatoč smanjenom broju parametara, model postiže visoku preciznost, što omogućuje robotsku manipulaciju u realnom vremenu uz nultu latenciju.