

Perceptivno-manipulacijski  
sustav za autonomni pick-and-  
place nepravilnih objekata

# Cilj zadatka je implementirati cjelovit perceptivno-manipulacijski sustav na UR robotskoj ruci koristeći:

- RealSense RGB-D kameru
- Obradu point cloud podataka
- Kalibraciju koordinatnih sustava
- Generiranje trajektorija
- TCP/IP komunikaciju s robotom
- Soft gripper za manipulaciju objektima nepravilnog oblika

# Sustav mora autonomno:

1. Detektirati zadani objekt u sceni
  2. Procijeniti njegovu 3D poziciju
  3. Transformirati koordinatu u koordinatni sustav baze robota
  4. Generirati trajektoriju
  5. Izvršiti pick-and-place zadatak
- **Svaki student samostalno implementira zadatak.**

# Radno okruženje:

Sustav se implementira koristeći:

- UR robot,
- RealSense kameru,
- C++/Python,
- OpenCV,
- PCL biblioteku,
- TCP/IP komunikaciju s robotom

**Potrebno je koristiti metode i predznanja s kolegija:** Industrijske i računalne mreže, Algoritmi strojnog vida te Humanoidni roboti i biomimetički sustavi

# 1. Kalibracije:

**Kalibracija TCP-a:** definirati i kalibrirati TCP soft grippera

**Kalibracija kamere:** potrebno je odrediti odnos TCP-a soft grippera i kamere (eye-in-hand)



Kamera i nosač



piSOFTGRIP Piab soft gripper

## 2. Snimanje scene:

**Potrebno je snimiti:** najmanje 3 point clouda iste scene (3 različite pozicije robota/kamere).

Pozicije snimanja moraju biti različite tako da se dobije dodatna geometrijska informacija scene

**Scena sadrži:** više objekata nepravilnog oblika (3D printano voće). U sceni je potrebno smjestiti po jedan objekt svakog tipa voća (7 ukupno).



### 3. Obrada point cloud podataka:

Potrebno je implementirati kompletan pipeline obrade point clouda

**Obavezni koraci:** filtriranje, uklanjanje outliera, downsampling, registracija point cloudova, stitching/fuzija point cloudova, ICP ili druga metoda registracije, segmentacija objekata

**Potrebno je koristiti metode obrađene na predavanjima i vježbama:** PassThrough, StatisticalOutlierRemoval, VoxelGrid, SACSegmentation, EuclideanClusterExtraction, ICP, RANSAC, i druge metode iz PCL biblioteke.

**Nakon ovog koraka potrebno je imati jedan konačni registrirani point cloud scene.**

## 4. Detekcija i lokalizacija objekta:


- Svaki student ima točno definirani objekt koji mora dohvatiti (tablica)
- Potrebno je:
  1. Segmentirati zadani objekt
  2. Pronaći njegov centar
  3. Odrediti 3D koordinatu objekta u koordinatnom sustavu kamere
  4. Transformirati koordinatu u koordinatni sustav baze robota
- Koordinate objekta **NE SMIJU** biti:
  - Ručno zadane,
  - Ručno naučene,
  - Unaprijed poznate
- Pozicija mora biti određena isključivo iz podataka kamere.

| Objekt        | Student   |
|---------------|-----------|
| Orah          | Akrap     |
| Banana        | Ćuk       |
| Naranča       | Gugo      |
| Crvena jabuka | Hartl     |
| Limun         | Noršić    |
| Zelena jabuka | Pongračić |



## 5. Pick and place:

- Robot mora autonomno izvršiti izuzimanje, prienos i odlaganje objekta
- Obavezne točke trajektorije:
  1. HOME
  2. APPROACH iznad objekta
  3. PICK
  4. APPROACH PLACE iznad mjesta odlaganja
  5. PLACE
- PICK – podaci dobiveni iz point clouda
- PLACE – može biti fiksno i unaprijed određena
- Kretnje između točaka ostvaruju se vlastitim generiranim trajektorijama  
(detaljne upute na sljedećem slajdu)



## 6. Generiranje trajektorija:

- Definicija trajektorije:
  - Definirana u task space-u
  - Robot mora prolaziti kroz svaku zadanu točku (nema blendinga radijusa)
  - Robotu se šalje samo  $x_{ref}$  (kao što smo na vježbi slali simulatoru robota) – PAZITE DA STE DOVOLJNO DISKRETIZIRALI KRETNJU
  - Robot radi 'control' dio - Robot izvršava samo niskorazinsku regulaciju i praćenje zadanih referenci
  - APPROACH iznad objekta i APPROACH PLACE iznad mjesta odlaganja moraju biti definirane u odnosu na PICK i PLACE fiksno (npr. offset po z-osi za 100 mm)
  - Trajektorije **MORAJU** poštovati ograničenja robota, biti izvedive i biti glatke

**TIJEKOM PUŠTANJA PROGRAMA POTREBNO JE PAZITI NA SUDARE SA STOLOM, SUDARE S OBJEKTIMA, NAGLE PROMJENE BRZINA – potrebno je konstantno biti na oprezu da ne dođe do ozljede studenata ili oštećenja opreme**

## 7. Upute za predaju:

- Svaki studenat predaje svoje izvješće
- Svako se izvješće sastoji od videozapisa, cjelovitog koda korištenog za rješavanje svih dijelova zadatka te pisanog dijela izvješća
- Predajete .zip datoteku sa svim materijalima
- Rok predaje: **22.5.2026., 23:59**
- Ovaj zadatak nosi 15% ukupne ocjene kolegija

## 7. Upute za predaju - videozapis:

- Potrebno je predati videozapis koji prikazuje kompletan pipeline rada sustava.
- Video mora sadržavati:
  1. snimanje point cloudova scene,
  2. odlazak robota po objekt,
  3. podizanje objekta,
  4. ostavljanje objekta na zadanu lokaciju
- Nakon što robot pokupi i ostavi predmet jednom, potrebno je bez zaustavljanja videozapisa predmet staviti na novo mjesto te još jednom pokrenuti pipeline
- Video ne mora biti montiran niti profesionalno obrađen, ali svi ključni koraci rada sustava moraju biti jasno prikazani. Tijekom demonstracije nije dozvoljena ručna intervencija u izvođenju pipeline-a.

## 7. Upute za predaju – pisano izvješće:

- Izvješće mora biti kratko i tehnički strukturirano, te je maksimalna duljina 10 stranica
- Nije potrebno pisati teorijski uvod niti objašnjavati korištene metode pošto su sve prethodno obrađene na nastavi
- Izvješće mora sadržavati:
  - Arhitekturu sustava (pipeline, kratki opis svakog modula)
  - Kalibracija (matrice transformacija)
  - Obradu PC-a (za svaki PC prikazati originalni PC, filtrirani PC, segmentirani PC te konačno prikazati rezultat registracije sva tri PC-a uz navođenje korištenih metoda te odabranih parametara)
  - Detekcija objekata (način segmentacije, određivanje centra objekta)
  - Generiranje trajektorija (potrebno je napraviti analizu jedne cjelovite trajektorije (sve generirane točke, vremena svih međutrajektorija, vizualizaciju svih međutrajektorija s istaknutih pet glavnih TCP poza, za jedan segment (međutrajektoriju) potrebno je prikazati grafove  $x(t)$ ,  $\dot{x}(t)$ ,  $\ddot{x}(t)$ )